UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Facultad de Ciencias

PROYECTO 1

— Cierre Fase 1 —

♡ Salas Reyes Sac-Nicté Damayanti ♡

10 Abril 2026

1. Tarea lingüística

El proyecto abordará una tarea de **clasificación de texto**, específicamente un **análisis de sentimiento** sobre reseñas de cafeterías. Formalmente, dado un conjunto de textos $X = \{x_1, x_2, \ldots, x_n\}$, se busca aprender una función de clasificación:

$$f : X \to Y, \quad Y = \{-1, 0, 1\}$$

donde -1 representa sentimiento negativo, 0 neutral y 1 positivo. El objetivo es aproximar f mediante un modelo paramétrico f_θ que maximice:

$$\max_\theta \prod_{i=1}^{n} P(y_i \mid x_i; \theta)$$

2. Corpus

Se utilizará un corpus en español de **reseñas de cafeterías en Ciudad de México**, almacenado en formato `.csv`. Para pruebas iniciales, se empleará un dataset obtenido de **Kaggle**, el cual será filtrado y adaptado al dominio específico.

Cada texto x_i se representará como una secuencia de tokens:

$$x_i = (w_1, w_2, \ldots, w_T)$$

Se considerará un preprocesamiento que incluya limpieza de ruido, normalización y tokenización.

3. Arquitectura base

Se utilizará un modelo **encoder-only** tipo BERT, el cual genera representaciones contextuales bidireccionales. Dado un texto x, el modelo produce:

$$\mathbf{h} = \mathrm{BERT}(x)$$

y la predicción se obtiene mediante:

$$\hat{y} = \mathrm{softmax}(W\mathbf{h}_{[\mathrm{CLS}]} + b)$$

Esta arquitectura es adecuada porque permite capturar dependencias semánticas complejas y ha demostrado alto rendimiento en tareas de clasificación [1].

Aunque modelos encoder–decoder (como T5 o BART) pueden adaptarse a tareas de clasificación formulándolas como generación de etiquetas, esto introduce complejidad innecesaria. En contraste, los modelos encoder-only están específicamente diseñados para tareas discriminativas, resultando más eficientes tanto en entrenamiento como en inferencia.

4. Baseline

Como baseline, se evaluará un modelo preentrenado sin *fine-tuning*, utilizando sus representaciones generales o esquemas *zero-shot*. Se espera una precisión moderada, suficiente para capturar tendencias generales de polaridad.

La función de pérdida considerada será la entropía cruzada:

$$\mathcal{L} = -\sum_{i=1}^{n} \sum_{c \in Y} y_{i,c} \log \hat{y}_{i,c}$$

5. Motivación

El análisis de sentimiento permite transformar opiniones subjetivas en información estructurada. En el contexto de cafeterías, esto puede utilizarse para detectar áreas de mejora y diseñar estrategias como descuentos dirigidos o mejoras en el servicio.

Este proyecto ilustra la aplicación de técnicas de PLN en español en un entorno real, contribuyendo a la toma de decisiones basada en datos [3].

Referencias

Referencias

[1] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. Proceedings of NAACL-HLT, 2019.
Disponible en: https://arxiv.org/abs/1810.04805
Consultada en Marzo de 2026.

[2] Liu, B. *Sentiment Analysis and Opinion Mining*. Synthesis Lectures on Human Language Technologies, Morgan & Claypool Publishers, 2012. ISBN 978-1608458844.
Consultada en Marzo de 2026.

[3] Jurafsky, D., & Martin, J. H. *Speech and Language Processing*. 3rd edition (draft), Stanford University, 2023.
Disponible en: https://web.stanford.edu/ jurafsky/slp3/
Consultada en Marzo de 2026.